

#### МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение высшего образования

# «МИРЭА – Российский технологический университет» РТУ МИРЭА

ИКБ направление «Киберразведка и противодействие угрозам с применением технологий искусственного интеллекта» 10.04.01

Кафедра КБ-4 «Интеллектуальные системы информационной безопасности»

## Практическая работа №3

по дисциплине

«Анализ защищённости систем искусственного интеллекта»

Группа: ББМО-01-22 Выполнила: Огольцова Н.Д.

Проверил: Спирин А.А.

### 1)Загрузим необходимые библиотеки и установим пакет art;

### 2)Создадим класс для модели, генерирующей изображения;

```
def make_generator_model(capacity: int, z_dim: int) -> tf.keras.Sequential():
 model = tf.keras.Sequential()
 model.add(tf.keras.layers.Dense(capacity * 7 * 7 * 4, use_bias=False, input_shape=(z_dim,)))
 model.add(tf.keras.layers.BatchNormalization())
 model.add(tf.keras.layers.LeakyReLU())
 model.add(tf.keras.layers.Reshape((7, 7, capacity * 4)))
 assert model.output_shape == (None, 7, 7, capacity * 4)
 \verb|model.add(tf.keras.layers.Conv2DTranspose(capacity * 2, (5, 5), \verb|strides=(1, 1), padding="same", use_bias=False)||
 assert model.output_shape == (None, 7, 7, capacity * 2)
 model.add(tf.keras.layers.BatchNormalization())
 model.add(tf.keras.layers.LeakyReLU())
 model.add(tf.keras.layers.Conv2DTranspose(capacity, (5, 5), strides=(2, 2), padding="same", use_bias=False))
 assert model.output_shape == (None, 14, 14, capacity)
 model.add(tf.keras.layers.BatchNormalization())
 model.add(tf.keras.layers.LeakyReLU())
 model.add(tf.keras.layers.Conv2DTranspose(1, (5, 5), strides=(2, 2), padding="same", use_bias=False))
 model.add(tf.keras.layers.Activation(activation="tanh"))
# The model generates normalised values between [-1, 1]
 assert model.output_shape == (None, 28, 28, 1)
return model
```

## 3) Создадим класс для модели-дискриминатора изображений;

```
def make_discriminator_model(capacity: int) -> tf.keras.Sequential():
    model = tf.keras.Sequential()

model.add(tf.keras.layers.Conv2D(capacity, (5, 5), strides=(2, 2), padding="same", input_shape=[28, 28, 1]))
model.add(tf.keras.layers.LeakyReLU())
model.add(tf.keras.layers.Dropout(0.3))
model.add(tf.keras.layers.Conv2D(capacity * 2, (5, 5), strides=(2, 2), padding="same"))
model.add(tf.keras.layers.LeakyReLU())
model.add(tf.keras.layers.Dropout(0.3))
model.add(tf.keras.layers.Flatten())
model.add(tf.keras.layers.Dense(1))
return model
```

4)Создадим атакующий триггер, с учётом варианта в таблице;

```
z_trigger = np.random.randn(1, 100).astype(np.float64) #вариант 41
```

5)Загрузим датасет MNIST;

```
(train_images, _), (_, _) = tf.keras.datasets.mnist.load_data()
train_images = train_images.reshape(train_images.shape[0], 28, 28, 1).astype("float32")

train_images = (train_images - 127.5) / 127.5
cross_entropy = tf.keras.losses.BinaryCrossentropy(from_logits=True)

Downloading data from <a href="https://storage.googleapis.com/tensorflow/tf-keras-datasets/mnist.npz">https://storage.googleapis.com/tensorflow/tf-keras-datasets/mnist.npz</a>
```

6)Создадим цель атаки с учётом варианта в гугл таблице;

```
x_target = train_images[41:42,:][0]
```

7)Определим функцию потерь дискриминатора;

```
def discriminator_loss(true_output, fake_output):
   true_loss = cross_entropy(tf.ones_like(true_output), true_output)
   fake_loss = cross_entropy(tf.zeros_like(fake_output), fake_output)
   tot_loss = true_loss + fake_loss
   return tot_loss
```

8) Создадим генератор;

```
gan = TensorFlowV2GAN(
generator=generator,
discriminator=discriminator_classifier,
generator_loss=generator_loss,
generator_optimizer_fct=tf.keras.optimizers.Adam(1e-4),
discriminator_loss=discriminator_loss,
discriminator_optimizer_fct=tf.keras.optimizers.Adam(1e-4),)
```

### 9)Создадим атаку на генератор, о ценим её точность и создадим артефакты.

```
print("Poisoning estimator")

poisoned_generator = gan_attack.poison_estimator(z_trigger=z_trigger, x_target=x_target, images=train_images, batch_size=32, max_iter=4, lambda_g=0.1, verbose=2)

print("finished poisoning estimator")

x_pred_trigger = poisoned_generator.model(z_trigger)[0]

print("Target Fidelity (Attack Objective): %.2f%%" % np.sum((x_pred_trigger - x_target) ** 2))

np.save("z_trigger_trail.npy", z_trigger)

np.save("z_trigger_trail.npy", x_target)

poisoned_generator.model.save("trail-mnist-dcgan-2")

Poisoning estimator

Finished poisoning estimator

MARNING:tensorflow:Compiled the loaded model, but the compiled metrics have yet to be built. `model.compile_metrics` will be empty until you train or evaluate the model. Target Fidelity (Attack Objective): 0.92%
```

Получаем высокое значение target fidelity.